



# 中國人民大學

RENMIN UNIVERSITY OF CHINA

**XXXX**

XXXXX

学院 \_\_\_\_\_

专业 \_\_\_\_\_

学号 \_\_\_\_\_

姓名 \_\_\_\_\_

2025 年 8 月 28 日

---

## 摘 要

XXXXX

关键词：XXX

# 目录

<b>1</b>	<b>问题设定与基本概念</b>	<b>1</b>
<b>2</b>	<b>线性分类器与超平面</b>	<b>1</b>
2.1	法向量与正交性质 . . . . .	1
2.2	带符号距离与原点距离 . . . . .	1
2.3	点到超平面的距离（通式） . . . . .	2
<b>3</b>	<b>质心法（Centroid Method）</b>	<b>2</b>
<b>4</b>	<b>线性可分与感知机（Perceptron）</b>	<b>2</b>
4.1	算法设定 . . . . .	2
4.2	约束、损失与风险 . . . . .	2
4.3	与梯度下降的关系与更新 . . . . .	3

## 1 问题设定与基本概念

给定  $n$  个样本，特征维度为  $d$ 。每个样本  $X_i \in \mathbb{R}^d$ ，部分属于类别  $C$ ，其余不属于  $C$ 。将样本视为  $\mathbb{R}^d$  中的点。

**判别函数 / 预测函数 / 判别式** (discriminant function) 定义为标量函数  $f(x)$ ，满足

$$f(x) > 0 \Rightarrow x \in C, \quad f(x) \leq 0 \Rightarrow x \notin C.$$

**决策边界** (decision boundary) 定义为零水平集

$$\{x \in \mathbb{R}^d : f(x) = 0\}.$$

它通常是  $\mathbb{R}^d$  中的一个  $(d-1)$  维曲面，即  $f$  在等值 0 处的**等值面** (isosurface)；类似地还有  $\{x : f(x) = 1\}$  等其它等值面。过度贴合训练集而产生蜿蜒曲线将导致**过拟合**。

## 2 线性分类器与超平面

若取线性判别函数

$$f(x) = w \cdot x + \alpha,$$

则决策边界为

$$H = \{x : w \cdot x = -\alpha\},$$

称  $H$  为**超平面** ( $d=2$  为直线,  $d=3$  为平面)。超平面的三条核心性质：

1. 维度为  $d-1$ ，将  $\mathbb{R}^d$  切分为两半；
2. 平直（由一次方程定义，无曲率）；
3. 无界（无限延伸）。

### 2.1 法向量与正交性质

若  $x, y \in H$ ，则

$$w \cdot (y - x) = 0.$$

因此  $w$  垂直于  $H$  上的任意方向， $w$  称为  $H$  的**法向量**。

### 2.2 带符号距离与原点距离

若  $w$  为单位向量，则  $f(x) = w \cdot x + \alpha$  是点到超平面  $H$  的**带符号距离**，正负号由法向量一侧决定； $H$  到原点的距离为  $|\alpha|$ ，且  $\alpha = 0$  当且仅当  $H$  过原点。若  $w$  非单位向量，可将  $w, \alpha$  同时除以  $\|w\|$  归一化。 $w$  与  $\alpha$  的系数统称为**权重 / 回归系数** (weights)。

## 2.3 点到超平面的距离（通式）

对任意  $w \neq 0$ ，点  $x_0$  到  $H: w \cdot x + \alpha = 0$  的距离

$$d(x_0, H) = \frac{|w \cdot x_0 + \alpha|}{\|w\|}.$$

当  $w$  为单位向量时， $f(x)$  即上述距离的带符号形式。

## 3 质心法（Centroid Method）

记正类与负类（非  $C$ ）的样本均值为

$$\mu_C = \frac{1}{|C|} \sum_{X_i \in C} X_i, \quad \mu_X = \frac{1}{|X|} \sum_{X_i \notin C} X_i.$$

采用判别函数

$$f(x) = (\mu_C - \mu_X) \cdot x - (\mu_C - \mu_X) \cdot \frac{\mu_C + \mu_X}{2}.$$

几何意义：法向量为  $\mu_C - \mu_X$ ；决策边界为连接  $\mu_C$  与  $\mu_X$  线段的垂直平分超平面。在某些数据上（即便线性可分）此方法仍可能误分；但当正负类分别来自两个高斯分布且协方差矩阵相同时，常表现良好。亦可调节标量项  $\alpha$ （不改变法向量）以减少误分。

**与贝叶斯最优分类器的联系** 若  $x|C_k \sim \mathcal{N}(\mu_k, \sigma^2 I)$  且先验相近，则

$$\log p(x|C_1) - \log p(x|C_2) \propto -\frac{1}{2\sigma^2} (\|x - \mu_1\|^2 - \|x - \mu_2\|^2),$$

等价于“判给更近的质心”。此时质心法与 LDA 的线性边界一致，达到贝叶斯最优；若协方差不同，则最优边界为二次曲面（QDA）。

## 4 线性可分与感知机（Perceptron）

**线性可分**：存在某个超平面能将全部训练点正确划分。

### 4.1 算法设定

样本行向量  $X_i$  存于矩阵  $X$  的第  $i$  行，标签

$$y_i = \begin{cases} 1, & X_i \in C, \\ -1, & X_i \notin C. \end{cases}$$

为简便先考虑过原点的边界（后续可加偏置）。

### 4.2 约束、损失与风险

目标是找到  $w$  使

$$y_i(X_i \cdot w) \geq 0 \quad (\forall i).$$

---

定义分段线性损失函数

$$L(z, y_i) = \begin{cases} 0, & y_i z \geq 0, \\ -y_i z, & y_i z < 0, \end{cases}$$

并令风险函数

$$R(w) = \frac{1}{n} \sum_{i=1}^n L(X_i \cdot w, y_i) = \frac{1}{n} \sum_{i: y_i X_i \cdot w < 0} (-y_i X_i \cdot w).$$

若  $w$  正确分类全部样本则  $R(w) = 0$ ; 否则  $R(w) > 0$ , 训练目标为

$$\min_w R(w).$$

### 4.3 与梯度下降的关系与更新

对误分类样本  $i$ , 有  $\nabla_w L(X_i \cdot w, y_i) = -y_i X_i$ 。随机梯度下降更新为

$$w \leftarrow w - \eta \nabla_w L = w + \eta y_i X_i,$$

当学习率  $\eta = 1$  即经典感知机更新。感知机针对线性可分数据“慢但正确”；若数据不可分则不收敛。它不追求最大间隔，鲁棒性不如 SVM。

