



中國人民大學

RENMIN UNIVERSITY OF CHINA

XXXX

XXXXX

学院 _____

专业 _____

学号 _____

姓名 _____

2025 年 8 月 29 日

摘 要

XXXXX

关键词：XXX

目录

| | |
|-------------------------------------|----------|
| 1 问题背景与动机 | 1 |
| 1.1 硬间隔 SVM 的局限 | 1 |
| 1.2 软间隔思想 | 1 |
| 2 软间隔 SVM：约束、几何与优化 | 1 |
| 2.1 松弛变量与几何解释 | 1 |
| 2.2 原始问题（QP）与参数 C | 1 |
| 2.3 偏置与同质化 | 2 |
| 3 非线性边界：特征与升维 | 2 |
| 3.1 总路线 | 2 |
| 3.2 抛物提升映射：球面 \leftrightarrow 超平面 | 2 |
| 3.3 二次曲面（Quadrics）与二次特征 | 2 |
| 3.4 一般 p 次多项式边界与升维的普适性 | 3 |
| 3.5 核技巧（Kernel Trick） | 3 |
| 4 次数、间隔与泛化：复杂度权衡 | 3 |
| 4.1 提高次数的双重效应 | 3 |
| 4.2 训练与测试误差随复杂度的典型曲线 | 3 |
| 4.3 与 C 的联动调参 | 3 |
| 5 特征工程：从多项式到任务特定特征 | 4 |
| 5.1 边缘检测与 HOG | 4 |
| 6 实践要点与建议 | 4 |

1 问题背景与动机

1.1 硬间隔 SVM 的局限

硬间隔 SVM 追求在训练集上严格线性可分并最大化间隔，但

1. 当数据不可线性可分时无可行解；
2. 对离群点高度敏感：单一点可显著改变最大间隔超平面；
3. 过于强调零训练误差，泛化受损。

1.2 软间隔思想

允许少量样本违反间隔（甚至被误分），用松弛变量刻画违约程度，在目标函数中惩罚之。几何上仍保持较宽的间隔，从而提升鲁棒性。

2 软间隔 SVM：约束、几何与优化

2.1 松弛变量与几何解释

给定样本 $\{(x_i, y_i)\}_{i=1}^n, x_i \in \mathbb{R}^d, y_i \in \{\pm 1\}$ ，判别函数

$$f(x) = \mathbf{w}^\top x + \alpha.$$

引入 $\xi_i \geq 0$ ，把硬间隔约束

$$y_i(\mathbf{w}^\top x_i + \alpha) \geq 1$$

放宽为

$$y_i(\mathbf{w}^\top x_i + \alpha) \geq 1 - \xi_i, \quad \xi_i \geq 0.$$

几何分类：

1. $\xi_i = 0$ ：样本在正确一侧且在间隔之外；
2. $0 < \xi_i < 1$ ：样本落入间隔区但仍正确分类；
3. $\xi_i \geq 1$ ：样本被误分。

软间隔的宽度仍定义为 $2/\|\mathbf{w}\|$ ；与硬间隔不同，最近训练点可侵入间隔。

2.2 原始问题（QP）与参数 C

$$\begin{aligned} \min_{\mathbf{w}, \alpha, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top x_i + \alpha) \geq 1 - \xi_i, \quad i = 1, \dots, n, \\ & \xi_i \geq 0, \quad i = 1, \dots, n. \end{aligned} \tag{1}$$

式 (1) 为二次规划：目标二次、约束线性。正则化超参数 $C > 0$ 在“最大化间隔”与“最小化训练误差”之间做权衡。

| | C 小 | C 大 |
|------|-------------------------|-------------------|
| 期望 | 更大间隔 $1/\ \mathbf{w}\ $ | 使大多数 ξ_i 逼近 0 |
| 风险 | 欠拟合（训练误差偏大） | 过拟合（对噪声敏感） |
| 对离群点 | 不敏感 | 极敏感 |

选择 C 通常用验证（交叉验证）完成。

2.3 偏置与同质化

原空间中 $f(x) = \mathbf{w}^\top x + \alpha$ ；同质化升维为

$$x' = (x, 1), \quad \mathbf{w}' = (\mathbf{w}, \alpha), \quad f(x) = \mathbf{w}'^\top x'.$$

注意 $\mathbf{w}^\top(x + \alpha)$ 无意义（维度不匹配）。

3 非线性边界：特征与升维

3.1 总路线

问题：在原空间不可线性可分。策略：构造非线性特征映射 $\Phi: \mathbb{R}^d \rightarrow \mathbb{R}^D$ ，在高维 Φ -空间用线性分类器，得到原空间的非线性边界。

3.2 抛物提升映射：球面 \leftrightarrow 超平面

取

$$\Phi(x) = \begin{bmatrix} x \\ \|x\|^2 \end{bmatrix} \in \mathbb{R}^{d+1}.$$

定理 1 (球 \leftrightarrow 超平面等价). 设原空间球 $\{x: \|x - c\|^2 < \rho^2\}$ 。则

$$\|x - c\|^2 < \rho^2 \iff \underbrace{\begin{bmatrix} -2c^\top & 1 \end{bmatrix}}_{\text{法向量}} \underbrace{\begin{bmatrix} x \\ \|x\|^2 \end{bmatrix}}_{\Phi(x)} < \rho^2 - \|c\|^2,$$

即“球内” \Leftrightarrow “升维后超平面之下”。超平面是半径 $\rightarrow \infty$ 的球的退化情形。

3.3 二次曲面 (Quadratics) 与二次特征

三维的一般二次曲面

$$Ax_1^2 + Bx_2^2 + Cx_3^2 + Dx_1x_2 + Ex_2x_3 + Fx_3x_1 + Gx_1 + Hx_2 + Ix_3 + \alpha = 0.$$

令

$$\Phi(x) = [x_1^2, x_2^2, x_3^2, x_1x_2, x_2x_3, x_3x_1, x_1, x_2, x_3]^\top,$$

则任意二次边界可写为线性形式 $f(x) = \mathbf{w}^\top \Phi(x) + \alpha$ 。当 d 大时交叉项数量为 $\mathcal{O}(d^2)$ ，计算代价显著；若仅保留平方项 x_j^2 ，新增维度线性增长，但边界只能与坐标轴对齐（不可任意旋转）。

3.4 一般 p 次多项式边界与升维的普适性

任意次数 $\leq p$ 的多项式

$$f(x) = \sum_{|\alpha| \leq p} c_\alpha x^\alpha, \quad x^\alpha = \prod_{j=1}^d x_j^{\alpha_j},$$

通过构造 $\Phi(x)$ 为所有次数 $\leq p$ 的单项式集合（维度 $\binom{d+p}{p}$ ），都有

$$f(x) = \mathbf{w}^\top \Phi(x),$$

从而在 Φ -空间线性化。这一结论说明：所有多项式形状的边界皆可通过合适升维变为超平面。但维度随 p 呈 $\mathcal{O}(d^p)$ 爆炸。

3.5 核技巧（Kernel Trick）

对偶形式仅依赖 $\langle \Phi(x_i), \Phi(x) \rangle$ 。定义核函数

$$K(x, z) = \langle \Phi(x), \Phi(z) \rangle,$$

即可无需显式计算 Φ 而在高维求解。典型示例：多项式核 $K(x, z) = (x^\top z + c)^p$ 、RBF 核等。核化使高阶多项式在计算上可行。

4 次数、间隔与泛化：复杂度权衡

4.1 提高次数的双重效应

1. 充分高的次数可使原本不可分的数据在高维变为线性可分；
2. 次数升高常见到更宽的有效间隔（在合适的正则下），但过高会过拟合。

4.2 训练与测试误差随复杂度的典型曲线

随模型复杂度（例如次数 p 或等效自由度）上升，训练误差单调下降；测试误差先降后升。最佳点位于两者平衡处（例如二次决策在示例中给出最小测试误差）。

4.3 与 C 的联动调参

若同时使用多项式特征与软间隔 SVM，需要联合选择

1. 多项式次数 p （控制表示能力）；
2. 正则化超参数 C （控制容错与间隔）。

一般地，不同 p 下的最优 C 不同，改变 p 时应重新验证 C 。

5 特征工程：从多项式到任务特定特征

5.1 边缘检测与 HOG

在图像任务中，直接使用原始像素对光照/位置/噪声敏感。可先用 Sobel/方向性高斯导数等算子近似梯度，再在局部网格统计梯度方向直方图（如每块 12 个方向 bins），拼接为向量作为特征（HOG），再交由线性 SVM 训练。实证对比：像素 + 线性 SVM 的测试错误率远高于 HOG + 线性 SVM（错误率显著下降）。

说明 1. 该案例表明：合适的任务特征往往比单纯提升模型复杂度更能改善泛化。

6 实践要点与建议

1. 先做标准化与特征工程，必要时再用核方法提升表示力；
2. 用交叉验证联合调参：次数/核参数与 C ；
3. 关注鲁棒性：数据含噪/离群点时优先软间隔；
4. 维度-计算量-过拟合三者权衡：去交叉项可显著降维，代价是边界受限（轴对齐）。

附录 A：对偶与核化

A.1 原始问题与拉格朗日函数

软间隔 SVM 的原始（Primal）二次规划为

$$\begin{aligned} \min_{\mathbf{w}, \alpha, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top x_i + \alpha) \geq 1 - \xi_i, \quad i = 1, \dots, n, \\ & \xi_i \geq 0, \quad i = 1, \dots, n, \end{aligned} \tag{2}$$

其中 $x_i \in \mathbb{R}^d$, $y_i \in \{\pm 1\}$, $C > 0$ 为正则化超参数。引入拉格朗日乘子

$$\lambda_i \geq 0 \quad \text{对应约束 } y_i(\mathbf{w}^\top x_i + \alpha) \geq 1 - \xi_i, \quad \mu_i \geq 0 \quad \text{对应约束 } \xi_i \geq 0.$$

拉格朗日函数

$$\mathcal{L}(\mathbf{w}, \alpha, \xi; \lambda, \mu) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \lambda_i [y_i(\mathbf{w}^\top x_i + \alpha) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i. \tag{3}$$

A.2 KKT 条件与驻点

对 $\mathbf{w}, \alpha, \xi_i$ 的一阶驻点条件 (Stationarity) :

$$\frac{\partial \mathcal{L}}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^n \lambda_i y_i x_i = \mathbf{0} \Rightarrow \mathbf{w}^* = \sum_{i=1}^n \lambda_i y_i x_i, \quad (4)$$

$$\frac{\partial \mathcal{L}}{\partial \alpha} = - \sum_{i=1}^n \lambda_i y_i = 0 \Rightarrow \sum_{i=1}^n \lambda_i y_i = 0, \quad (5)$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C - \lambda_i - \mu_i = 0 \Rightarrow 0 \leq \lambda_i \leq C, \quad \mu_i = C - \lambda_i. \quad (6)$$

再加上原始可行性 (Primal feasibility)

$$y_i(\mathbf{w}^\top x_i + \alpha) \geq 1 - \xi_i, \quad \xi_i \geq 0,$$

对偶可行性 (Dual feasibility) $\lambda_i \geq 0, \mu_i \geq 0 (\Rightarrow 0 \leq \lambda_i \leq C)$, 以及互补松弛 (Complementary slackness) :

$$\lambda_i [y_i(\mathbf{w}^\top x_i + \alpha) - 1 + \xi_i] = 0, \quad (7)$$

$$\mu_i \xi_i = 0. \quad (8)$$

由于问题满足 Slater 条件 (取 $\mathbf{w} = \mathbf{0}, \alpha = 0, \xi_i = 2$ 即严格可行), 强对偶成立, KKT 为充要最优条件。

A.3 消元得到对偶问题

将 (4) 代入 (3) 并最小化掉原始变量, 得到对偶 (Dual):

$$\begin{aligned} \max_{\lambda} \quad & \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (x_i^\top x_j) \\ \text{s.t.} \quad & \sum_{i=1}^n \lambda_i y_i = 0, \quad 0 \leq \lambda_i \leq C, \quad i = 1, \dots, n. \end{aligned} \quad (9)$$

该目标函数关于 λ 为严格凹函数 (负半定二次型), 带线性约束的凹优化, 标准 QP 可用 SMO 等算法求解。

A.4 偏置项的恢复与判别函数

求得最优 λ^* 后, 由 (4) 有

$$\mathbf{w}^* = \sum_{i=1}^n \lambda_i^* y_i x_i.$$

对任一边界支持向量 k (满足 $0 < \lambda_k^* < C$, 此时 (7) 给出 $y_k(\mathbf{w}^{*\top} x_k + \alpha^*) = 1$), 可恢复偏置

$$\alpha^* = y_k - \sum_{i=1}^n \lambda_i^* y_i (x_i^\top x_k). \quad (10)$$

实践中可对所有 $0 < \lambda_k^* < C$ 的样本求得的 (10) 取平均以减小数值误差。最终判别函数为

$$f(x) = \text{sign} \left(\sum_{i=1}^n \lambda_i^* y_i (x_i^\top x) + \alpha^* \right). \quad (11)$$

分类几何解释：间隔宽度为 $2/\|\mathbf{w}^*\|$ 。样本类型与 KKT 的对应关系：

1. $\lambda_i^* = 0 \Rightarrow \xi_i^* = 0, y_i(\mathbf{w}^{*\top} x_i + \alpha^*) \geq 1$ ：在间隔外，非支持向量；
2. $0 < \lambda_i^* < C \Rightarrow \xi_i^* = 0, y_i(\mathbf{w}^{*\top} x_i + \alpha^*) = 1$ ：边界支持向量；
3. $\lambda_i^* = C \Rightarrow y_i(\mathbf{w}^{*\top} x_i + \alpha^*) = 1 - \xi_i^* \leq 1$ ：在间隔内或被误分的错误/软支持向量。

A.5 与合页损失（Hinge Loss）的等价

原始问题 (2) 可改写为正则化风险最小化：

$$\min_{\mathbf{w}, \alpha} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \ell_{\text{hinge}}(y_i, \mathbf{w}^\top x_i + \alpha), \quad \ell_{\text{hinge}}(y, t) = \max\{0, 1 - yt\}. \quad (12)$$

证明要点：对给定 (\mathbf{w}, α) ，对每个 i 的最优 ξ_i 来自

$$\min_{\xi_i \geq 0} C \xi_i \quad \text{s.t.} \quad \xi_i \geq 1 - y_i(\mathbf{w}^\top x_i + \alpha),$$

其最优解为 $\xi_i^* = \max\{0, 1 - y_i(\mathbf{w}^\top x_i + \alpha)\}$ ，代回得到 (12)。这说明 SVM 是“二范数正则化 + 合页损失”的最大间隔分类器。

A.6 核化（Kernelization）

在对偶 (9) 与判别 (11) 中，数据仅以内积 $x_i^\top x_j$ 、 $x_i^\top x$ 出现。定义核函数

$$K(x, z) = \langle \Phi(x), \Phi(z) \rangle,$$

其中 $\Phi(\cdot)$ 是（可能高维/无限维的）特征映射，且 K 对称且正定。将所有内积替换为核函数：

$$\begin{aligned} \max_{\lambda} \quad & \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j K(x_i, x_j) \\ \text{s.t.} \quad & \sum_{i=1}^n \lambda_i y_i = 0, \quad 0 \leq \lambda_i \leq C. \end{aligned} \quad (13)$$

$$f(x) = \text{sign} \left(\sum_{i=1}^n \lambda_i^* y_i K(x_i, x) + \alpha^* \right). \quad (14)$$

常见核：线性核 $K(x, z) = x^\top z$ 、多项式核 $K(x, z) = (x^\top z + c)^p$ 、RBF 核 $K(x, z) = \exp(-\|x - z\|^2 / (2\sigma^2))$ 等。核化避免了显式构造 Φ 及其维度爆炸。

A.7 硬间隔与极限情形

当数据严格可分且取 $C \rightarrow \infty$ 时，软间隔对偶 (13) 退化到硬间隔的对偶，最优解强制 $\xi_i^* = 0$ ，得到经典最大间隔分离超平面。

A.8 计算与实现要点

1) 对偶问题是带盒约束与一个等式约束的凹 QP, SMO 类分解方法高效稳定; 2) 偏置 α^* 建议在所有 $0 < \lambda_i^* < C$ 的边界支持向量上取平均; 3) 特征缩放与核参数 (如多项式次数、RBF 的 σ) 必须与 C 一经验证优化。

小结: 软间隔 SVM 的对偶仅依赖样本的成对相似度 (内积/核), 最优解由少量支持向量决定; 核技巧在不显式升维的情形下实现了高维线性分割, 从而在原空间产生非线性决策边界。

附录 B: 常见核与特征维度增长

1. 多项式核 $K(x, z) = (x^\top z + c)^p$, 对应显式特征维度 $\binom{d+p}{p}$;
2. RBF 核 $K(x, z) = \exp(-\frac{\|x-z\|^2}{2\sigma^2})$, 对应无限维特征;
3. 仅平方项时新增维度 $\mathcal{O}(d)$, 包含交叉项时为 $\mathcal{O}(d^2)$ 。
